

项目二：资金流入流出预测系统 — 需求分析与最小可跑通方案

指导教师：夏艳 | 2026年5月
基于天池「资金流入流出预测」赛题 (<https://tianchi.aliyun.com/competition/entrance/231573/information>)

一、项目目标一句话总结

基于余额宝 2013.07.01 ~ 2014.08.31 的用户交易数据 + 收益率 + Shibor 利率，预测 **2014年9月1日~9月30日** 每一天的**申购总额**和**赎回总额**，并输出符合赛题格式的预测结果文件。

二、数据资产全景（4张表）

表1：用户信息表 `user_profile_table`

字段	类型	说明
user_id	bigint	用户ID
sex	bigint	1=男, 0=女
city	bigint	城市编码(脱敏)
constellation	string	星座

→ 约 28,000 训练用户 + 约 2,000 测试用户（2014-09 首次出现）

表2：用户申购赎回表 `user_balance_table`（核心大表）

字段	类型	说明
user_id	bigint	用户ID
report_date	string	日期(如 20140407)
tBalance	bigint	今日余额(分)
yBalance	bigint	昨日余额(分)

字段	类型	说明
total_purchase_amt	bigint	今日总申购 = 直接申购 + 收益
direct_purchase_amt	bigint	直接申购
purchase_bal_amt	bigint	支付宝余额申购
purchase_bank_amt	bigint	银行卡申购
total_redeem_amt	bigint	今日总赎回 = 消费 + 转账
consume_amt	bigint	消费金额
transfer_amt	bigint	转账金额
tftobal_amt	bigint	转入支付宝余额
tftocard_amt	bigint	转入银行卡
share_amt	bigint	当日收益
category1~4	bigint	消费类别(consum_amt=0时为null)

→ 约 280 万条记录，覆盖 2013.07.01 ~ 2014.08.31 (427天)

数据一致性约束： $tBalance = yBalance + total_purchase_amt - total_redeem_amt$ (无负值，已脱敏保证)

表3：收益率表 mfd_day_share_interest

字段	类型	说明
mfd_date	string	日期
mfd_daily_yield	double	万份收益(每万分收益，单位分)
mfd_7daily_yield	double	七日年化收益率(%)

表4：Shibor 利率表 mfd_bank_shibor

字段	类型	说明
mfd_date	string	日期
Interest_O_N	double	隔夜拆借(%)
Interest_1_W	double	1周(%)
Interest_2_W	double	2周(%)

字段	类型	说明
Interest_1_M	double	1月(%)
Interest_3_M	double	3月(%)
Interest_6_M	double	6月(%)
Interest_9_M	double	9月(%)
Interest_1_Y	double	1年(%)

三、核心任务拆解

阶段 0：数据探索（先看看数据长什么样）

- 加载 4 张表，打印 shape、dtypes、前5行、缺失值、基本统计量
- 验证 $tBalance = yBalance + total_purchase_amt - total_redeem_amt$
- 画出训练时段（2013.07 ~ 2014.08）的每日申购/赎回总额趋势图

阶段 1：数据预处理 & 特征工程

1. 从 `user_balance_table` 聚合每日总量
2. 按 `report_date` 分组，sum 得到每日 `total_purchase` 和 `total_redeem`
3. 这就是我们要预测的目标 y 序列
4. 合并收益率和利率
5. 按日期 merge `mfd_day_share_interest` 和 `mfd_bank_shibor`
6. 形成一张「日期 + 申购总额 + 赎回总额 + 万份收益 + 7日年化 + 8个Shibor」的大宽表
7. 构造时间特征
 8. `dayofweek`（周一~周日 0~6）
 9. `dayofmonth`（1~31）
 10. `month`（1~12）
 11. `is_weekend`（是否周末）
 12. 申购/赎回的滞后特征（`lag_1`, `lag_7`, `lag_30` 等）
 13. 申购/赎回的滚动窗口统计（`rolling_mean_7`, `rolling_std_7` 等）
14. 拆分训练/验证/测试

- 15. 训练集：2013.07.01 ~ 2014.07.31（训练）
- 16. 验证集：2014.08.01 ~ 2014.08.31（调参验证）
- 17. 测试集：2014.09.01 ~ 2014.09.30（最终预测）

阶段 2：建模预测（最小方案用 LightGBM）

- 模型：LightGBM（树模型，对表格数据效果好，训练快）
- 目标：两个回归任务—— purchase 和 redeem
- 策略：分别训练两个模型 OR 用一个多输出模型 → 最小方案分别训练两个
- 训练：在训练集上拟合，在验证集上看效果
- 预测：对测试集 30 天做预测（滚动预测：每天预测完把预测值当 lag 特征传给下一天）

阶段 3：输出提交文件

输出 tc_comp_predict_table.csv，格式：

report_date	purchase	redeem
20140901	123456789	98765432
...	...	...
20140930	...	...

- purchase 和 redeem 为整数（单位：分）
- 共 30 行

四、评估指标

每日相对误差：

$$Purchase_i = \frac{|\hat{y}_i^{pur} - y_i^{pur}|}{y_i^{pur}}$$

得分函数 $f(\cdot)$ 单调递减：

- error = 0 → 10 分
- error > 0.3 → 0 分

最终总分 = 申购得分 × 45% + 赎回得分 × 55%

注意：赛题不公布 $f(\cdot)$ 具体公式，但指导书明确了 error=0→10 分、error>0.3→0 分。我们可以近似用线性函数 $score = \max(0, 10 \times (1 - error / 0.3))$ 来模拟评估。

五、指导书额外要求：可交互可视化分析系统

指导书要求做 4 个模块的 Web 可视化系统。作为「最小可跑通」方案，建议用 **Streamlit** 快速搭建单页应用，核心功能：

模块	最小实现	Streamlit 组件
数据探索	历史申购/赎回趋势图、收益率变化图	<code>st.line_chart</code> / <code>plotly</code>
模型训练与评估	显示训练 loss、验证集对比	<code>st.metric</code> + <code>plotly</code>
预测结果展示	30天预测表格 + 折线图	<code>st.dataframe</code> + <code>st.line_chart</code>
误差分析	每日误差表、高亮大误差日	<code>st.dataframe</code> 带颜色

六、最小可跑通方案：技术选型 & 目录结构

技术栈

环节	工具
数据处理	Python + Pandas + NumPy
建模	LightGBM
可视化系统	Streamlit
图表	Plotly（交互式）

建议目录结构

```
project2_fund_forecast/
├─ data/                                # 数据文件夹（从平台下载的zip解压）
│   ├── user_profile_table.csv
│   ├── user_balance_table.csv
│   ├── mfd_day_share_interest.csv
│   └─ mfd_bank_shibor.csv
├─ src/
│   ├── preprocess.py                  # 数据预处理 + 特征工程
│   ├── train.py                      # LightGBM 训练
│   └─ predict.py                    # 滚动预测 30 天
```

```
|   └─ evaluate.py           # 评估函数（模拟评分）
|   └─ app.py                # Streamlit 可视化主入口
|   └─ output/
|       └─ tc_comp_predict_table.csv # 最终提交文件
|   └─ requirements.txt
```

依赖

```
pandas
numpy
lightgbm
scikit-learn
streamlit
plotly
```

七、代码执行流程（一次性跑通）

```
data/ → preprocess.py → 生成 features.csv
      ↓
      train.py → 训练 LightGBM 模型 → 保存 model_purchase.pkl, model_redeem.pkl
      ↓
      predict.py → 滚动预测 9月30天 → output/tc_comp_predict_table.csv
      ↓
      app.py → Streamlit 启动, 可视化全流程结果
```

八、关键注意事项（踩坑预警）

风险点	对策
数据需从天池下载（注册后）	提前注册天池账号并下载 zip 包（约23MB）
9月是预测目标，没有真实标签用于验证	用 8月数据做本地验证集，9月预测直接输出
滞后特征在预测时需滚动计算	predict.py 需要按天循环，每天预测完更新 lag 特征
申购/赎回值很大（日总量可能上亿分）	训练前可做 log1p 变换，预测后 expm1 还原
Streamlit 需要 Python 3.8+	确保环境兼容

九、数据下载指引

1. 访问 <https://tianchi.aliyun.com/competition/entrance/231573/information>
 2. 注册/登录天池
 3. 点击「报名」→ 进入赛题页 → 「数据下载」→ 下载 `p*****a.zip` (约23MB)
 4. 解压到 `data/` 目录即可使用
-

如有任何环节不清楚，随时可以问我继续推进。