

《大数据技术实训项目》 指导书

教 师 _____ 夏 艳 _____

时 间 _____ 2026 年 05 月 _____

目 录

项目一：中文古诗词理解与智能评测系统.....	3
项目二：资金流入流出预测系统.....	5
项目三：中文电子病历 ICD 自动编码系统.....	8
项目四：自选.....	11
附录一：课程相关知识点汇总.....	12
一、 编程语言	12
二、 数据库技术.....	12
三、 大数据采集.....	12
四、 数据处理.....	14
五、 大数据存储.....	15
六、 数据分析.....	16
七、 数据可视化.....	17
附录二：参考资料.....	19

项目一：中文古诗词理解与智能评测系统

项目背景与要求：

中文古诗词具有语言的高度凝练性、格律的严谨性和意境的丰富性，是中国优秀传统文化的重要载体。随着大语言模型和自然语言处理技术的快速发展，如何让计算机准确理解古诗词的字词含义、诗句意蕴、情感色彩、典故出处及诗词间的类比关联，已成为智能教育、文化数字化和中文信息处理交叉领域的重要研究方向。本项目要求设计一个中文古诗词理解与智能评测系统，能够针对给定的古诗词数据，自动完成字词理解、诗句理解、情感理解、典故识别、古诗词类比和古诗词辨析六大评测任务，并生成符合规范格式的预测结果。

本项目要求：

1. **数据采集与处理**：收集符合规范的古诗词数据，理解各任务的数据格式和标注规范；对采集的数据进行数据解析、清洗和结构化存储。

2. **构建评测模型**：针对不同任务的特点，选择和训练适合的模型或方法。

任务一：诗句理解与解析，要求对诗句中的关键词、短语进行精准释义（字词释义），解释其文化背景与引申义；能解析诗句的完整语义及隐含意境（句意翻译），还原作者创作意图；能识别并判断诗句表达的情感倾向（如爱国、哀婉、豁达等）。

任务二：文化典故溯源与推理，要求定位诗句中的历史典故、神话传说或文学引用，并阐释其渊源与象征意义；基于诗句内容，完成类比推理（如语义对应关系填空）与逻辑辨析（如错误选项识别）。

3. **模型评估与分析**：分析模型在不同任务和不同诗词类型（唐诗/宋词、五言/七言、绝句/律诗）上的表现差异，并探讨模型的优势与不足。各子任务的评价指标如下：

a. 字词理解：(BLEU + BERTScore)/2

- b. 诗句理解: $(\text{BLEU} + \text{BERTScore})/2$
- c. 情感理解: Accuracy
- d. 典故识别: $(\text{flag_Accuracy} + \text{BERTScore})/2$
- e. 古诗词类比: Accuracy
- f. 古诗词辨析: Accuracy

参考资料:

1. 数据集获取: <https://tianchi.aliyun.com/competition/entrance/532470/information>, 也可自行构建数据集。
2. Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]. NAACL, 2019.
3. Lewis, M., Liu, Y., Goyal, N., et al. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension[C]. ACL, 2020.
4. Zhang, T., Kishore, V., Wu, F., et al. BERTScore: Evaluating Text Generation with BERT[C]. ICLR, 2020.
5. 王力. 汉语诗律学[M]. 北京: 中华书局, 2021 年.
6. 袁行霈. 中国诗歌艺术研究[M]. 北京: 北京大学出版社, 2009 年.
7. 周振甫. 诗词例话[M]. 北京: 中国青年出版社, 2022 年.
8. 刘永济. 唐人绝句精华[M]. 南京: 江苏凤凰文艺出版社, 2024 年.

项目二：资金流入流出预测系统

项目背景与要求：

随着金融业务的快速发展，蚂蚁金服等大型金融平台每日面临海量资金的流入（申购）与流出（赎回），资金管理压力巨大。精准预判平台资金流动趋势，是保障金融流动性安全、优化资金配置的核心关键。本项目需完成一个资金流入流出预测系统，要求基于余额宝用户的真实交易数据、用户特征、市场利率等多维度信息，构建预测模型并开发可视化分析系统，为金融机构的流动性管理提供决策支持。

项目要求：

1. **数据预处理。**整合给定的四组数据表：用户信息表 (user_profile_table)、用户申购赎回数据表 (user_balance_table)、收益率表

(mfd_day_share_interest) 和银行间拆借利率表 (mfd_bank_shibor)，完成数据清洗、特征工程和数据集成与存储。注意确保数据一致性，例如验证“今日余额 = 昨日余额 + 今日申购 - 今日赎回”的逻辑关系。

2. **构建预测模型。**根据历史数据（2013年7月1日至2014年8月31日）预测未来30天（2014年9月1日至9月30日）每日的申购总额 (purchase) 和赎回总额 (redeem)。预测精度要求：根据评价指标（详见后文）评估模型性能，重点优化赎回预测（权重55%），确保总积分最大化。

3. **实现可交互可视化分析系统。**包括以下功能模块（具体细节可自定）：

① 数据探索模块：可展示历史申购赎回趋势图、用户分布、收益率变化等可视化图表，辅助分析数据规律；

② 模型训练与评估模块：允许用户选择不同模型或参数进行训练，并展示

训练过程中的损失曲线、交叉验证结果；

③ 预测结果展示模块：以表格和折线图形式展示未来30天的预测结果（申购/赎回），并与真实值（在验证集上）进行对比，计算每日误差和总积分；

④ 误差分析模块：显示每日申购和赎回的绝对误差、相对误差以及当日得分，高亮误差较大的日期，提供模型改进方向的可视化反馈。

评估指标：

评估指标的设计主要期望选手对未来 30 天内每一天申购和赎回的总量数据预测的越准越好，同时考虑到可能存在的多种情况。譬如有些选手在 30 天中 29 天预测都是非常精准的但是某一天预测的结果可能误差很大，而有些选手在 30 天中每天的预测都不是很精准误差较大，如果采用绝对误差则可能导致前者的成绩比后者差，而在实际业务中可能更倾向于前者。所以最终选用积分式的计算方法：每天的误差选用相对误差来计算，然后根据用户预测申购和赎回的相对误差，通过得分函数映射得到一个每天预测结果的得分，将 30 天内的得分汇总，然后结合实际业务的倾向，对申购赎回总量预测的得分情况进行加权求和，得到最终评分。具体的操作如下：

(1) 计算所有用户在测试集上每天的申购及赎回总额与实际情况总额的误差。

每日申购相对误差(真实值 z_i ，预测值为 $\hat{z}_i$)：

$$\text{Purchase}_i = \frac{|z_i - \hat{z}_i|}{z_i}$$

每日赎回相对误差(真实值 y_i ，预测值为 $\hat{y}_i$)：

$$\text{Redeem}_i = \frac{|y_i - \hat{y}_i|}{y_i}$$

(2) 申购预测得分与 Purchase_i 相关，赎回预测得分与 Redeem_i 相关，误差与得分之间的计算公式不公布，但保证该计算公式为单调递减的，即误差越小，得分越高，误差与大，得分越低。当第 i 天的申购误差 $\text{Purchase}_i = 0$ ，

这一天的得分为 10 分；当 $\text{Purchase}_i > 0.3$ ，其得分为 0。

(3) 最终总积分 = 申购预测得分 *45%+ 赎回预测得分 *55%。

参考资料：

1. 数据集获取：

<https://tianchi.aliyun.com/competition/entrance/231573/information>.

2. Hyndman, R. J., & Athanasopoulos, G. Forecasting: Principles and Practice (3rd ed.)[M]. OTexts: Melbourne, Australia, 2021.

3. Ke, G., Meng, Q., Finley, T., et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree[C]// NeurIPS, 2017.

4. 张春福, 白婧, 张良均等. Python数据分析与挖掘实战 (第3版). 机械工业出版社, 2025年.

5. (美) 韦斯麦金尼. 利用 Python 进行数据分析 (原书第 3 版) [M]. 北京: 机械工业出版社, 2023.

6. 徐国祥. 统计预测与决策 (第 5 版) [M]. 上海: 上海财经大学出版社, 2021.

项目三：中文电子病历 ICD 自动编码系统

项目背景与要求：

随着人口老龄化加剧和健康意识提升，医疗体系面临服务压力激增的挑战。电子病历的普及为医疗数据标准化与共享提供了新路径。世界卫生组织制定的国际疾病分类标准（International Classification of Diseases, ICD）将数万种疾病及其组合转化为规范的字母数字编码体系，为跨地区、跨机构的医疗数据交换与分析奠定了基础。然而，对电子病历文本进行人工ICD编码不仅耗时耗力，还容易因专业技能差异导致编码错误。开发自动ICD编码系统，既能提高编码效率和准确率，也能为疾病研究和医疗管理提供更可靠的数据支持。本项目要求基于中文电子病历文本，构建一个疾病与手术ICD自动编码系统。

本项目要求：

1. **数据预处理。**现有数据集源于脱敏病历，覆盖10个科室，涉及18种主要疾病编码（ICD-10国家临床版2.0）、若干其他疾病编码，16种主要手术编码（ICD-9-CM3国家临床版3.0）及若干其他手术编码。需对原始数据进行文本拼接与结构化解析、数据清洗、编码标准化和数据划分与存储。

2. **构建编码模型。**针对中文电子病历ICD自动编码的多任务、多标签分类特点，构建能够同时输出主要诊断编码、其他诊断编码、主要手术编码和其他手术编码的模型。具体建模目标：输入一段由临床信息构成的文本，输出对应的四种编码结果。其中主要诊断编码和主要手术编码均为单标签分类任务（各有约18类和16类），其他诊断编码和其他手术编码均为多标签分类任务（其他诊断编码候选类别约20+类，其他手术编码候选类别约16类）

预测精度要求：在验证集上综合指标M_total应达到0.85以上，综合指标计算公式为： $M_total = 0.4 \times Acc_main + 0.1 \times F1_other + 0.4 \times Acc_op_main + 0.1 \times F1_op_other$ （其中，Acc_main 和 Acc_op_main 分别表示主要诊断编码和主要手术编码的准确率，F1_other 和 F1_op_other 分别表示其他诊断编码和其他手术编码的宏平均F1值）。

3. 实现自动编码系统。包括数据管理模块、模型训练与监控模块、自动编码模块和模型评估与误差分析模块等。

- (1) 数据管理模块：支持训练集、验证集和测试集的数据导入；提供病历文本的分字段展示和拼接预览功能；支持编码字典的查询与浏览。
- (2) 模型训练与监控模块：可视化损失曲线、分项指标变化（主诊断准确率、其他诊断F1、主要手术准确率、其他手术F1）以及综合指标M_total的变化趋势；支持模型检查点的保存与加载。
- (3) 自动编码模块：支持单条病历文本的在线自动编码，以可视化方式展示模型输出的四种编码结果及其置信度；支持批量编码并生成符合评测要求的提交文件（纯文本格式，每行对应一个病历）。
- (4) 评估分析模块：在验证集上自动计算分项指标（Acc_main、F1_other、Acc_op_main、F1_op_other）和综合指标M_total；生成混淆矩阵（用于主诊断和主要手术编码分析）；统计其他诊断编码和其他手术编码的误报和漏报情况；对典型错误样本进行高亮展示和案例归因分析（如文本长度影响、科室差异、编码混淆等），为模型改进提供方向。

参考资料:

1. 数据集获取:

<https://tianchi.aliyun.com/competition/entrance/532466/information>.

2. Afkanpour, A., Adeel, S., Bassani, H., et al. BERT for Long Documents: A Case Study of Automated ICD Coding[C]. Proceedings of the 13th International Workshop on Health Text Mining and Information Analysis (LOUHI). Abu Dhabi: Association for Computational Linguistics, 2022.

3. Niu, K., et al. Retrieve and Rerank for Automated ICD Coding via Contrastive Learning[J]. Journal of Biomedical Informatics, 2023.

4. 余颖. 面向电子病历文本的疾病编码自动标注与预测方法[D]. 中南大学, 2022.

5. 李宛泽,宋波,齐岳山. 基于知识增强的中文电子病历命名实体识别[J]. 计算机系统应用, 2023, 32(12).

6. 周晓敏, 滕飞, 张艺. 基于元网络的自动国际疾病分类编码模型[J]. 计算机应用, 2023(9).

7. 徐春,涂二妹,马志龙. 基于标签注意力的分层 ICD 自动编码方法[J]. 计算机工程与设计, 2023, 44(7)

项目四：自选

自选项目要求：

可自选天池大数据竞赛中正在进行的一道赛题。

全部比赛

AI大模型赛

数据算法赛

工程开发赛

日常学习赛

请输入赛题名称搜索

卡片 列表



2026
CSIG图像图形技术挑战赛

AI大模型赛

CSIG图像图形技术挑战赛-...

CSIG图像图形技术挑战赛是由中国图象图形学学会（CSIG）主办的系列赛事，旨在促进图像图形技术及...

主办方

计算机视觉

立即报名

奖金

¥ 200000

团队数

22

比赛时间：2026.07.03 ~ 2026.09.15



2026
CSIG图像图形技术挑战赛

AI大模型赛

CSIG图像图形技术挑战赛-...

CSIG图像图形技术挑战赛是由中国图象图形学学会（CSIG）主办的系列赛事，旨在促进图像图形技术及...

主办方

计算机视觉

立即报名

奖金

¥ 200000

团队数

13

比赛时间：2026.07.01 ~ 2026.09.15



Qoder
码力星期四
世界杯冠军预测Agent
开发挑战赛

AI大模型赛

Qoder码力星期四·世界杯...

本次挑战赛要求参赛队伍开发一个世界杯冠军预测Agent。该 Agent 需具备数据采集、赛程分析、比分...

主办方

阿里云竞赛

微调大模型

大语言模型

立即报名

亮点

免费Credits

团队数

42

比赛时间：2026.07.02 ~ 2026.07.16

项目要求：

- 1、按照赛事要求在网上报名并组队参加。
- 2、课程最后一周，按照课程要求进行项目验收并提交相关程序和报告。

参考资料：

1. 天池大赛网站：<https://tianchi.aliyun.com/competition/>.

附录一：课程相关知识点汇总

一、编程语言

主流编程语言包含 Python、R 语言、Scala 和 Java 语言等，可根据需要自行学习。

- (1) Python: 数据分析、机器学习、数据预处理的主流工具 (如 Pandas、NumPy、PySpark) 。
- (2) R 语言: 统计建模、数据可视化 (如 ggplot2、tidyverse) 。
- (3) Scala: Spark、Flink 等大数据框架的核心开发语言。
- (4) Java: Hadoop 生态组件开发及企业级应用开发。

学习建议：根据实训需求选择核心语言，兼顾工具链兼容性。

二、数据库技术

常用大数据存储与数据库系统包括了分布式文件系统 Hadoop HDFS (高容错、高吞吐存储)、NoSQL、Apache Hive (基于 Hadoop 的 SQL-on-Hadoop 引擎)、Apache Kylin (OLAP 分析引擎) 和 AWS Redshift、Google BigQuery (托管数据仓库) 等。

三、大数据采集

大数据采集是指通过一定的技术手段和工具，从各种数据源获取原始数据，并将其转化为结构化或半结构化的数据存储格式。大数据采集是进行数据分析与应用的基础，在选择采集方法时需要综合考虑数据源、数据类型、采集工具和成本等因素。常用大数据采集方法与技术包括数据爬取、日志采集 Flume 和接口采集等。

- (1) **数据爬取：** 通过程序自动访问目标网站，并提取网页中包含的结构化数据。常见的爬虫工具有 Python 的 BeautifulSoup 和 Scrapy 等。数据爬取适用于从互联网获取大量公开信息，但由于需要处理网页结构和变化因素，其技术难度较大。数据爬取的优点是可以快速获取大量数据，缺点是容易受到反爬虫策略的限制，且需要解决网页更新和异常处理等问题。
- (2) **日志采集：** 通过收集应用程序、操作系统、网络设备等产生的日志数据，以提取有用的信息。常用的日志采集工具有 Flume（日志聚合）、Logstash（日志处理）、Filebeat（轻量采集），这些工具使用流式传输或文件传输方式，将日志数据汇聚到中央存储系统进行分析和处理。日志采集的优点是数据量大、可靠性高、易于扩展，缺点是需要手动配置日志格式和解析规则。其中，Flume 是 Cloudera 公司提供的分布式、可靠和高可用的海量日志采集、聚合和传输的系统。Flume 支持在日志系统中定制各类数据发送方，用于收集数据；同时，Flume 能对数据进行简单处理，并写入各类数据接收方，如文本、HDFS、HBase 等。
- (3) **接口采集：** 通过 API 接口从其他系统获取数据。API 是一种应用程序接口，它允许不同系统之间进行数据交换和集成。接口采集适用于对外部系统数据进行整合和对接，但由于需要与外部系统进行协调和对接，其技术难度和开发成本相对较高，主流技术：RESTful API、Webhooks、SDK 对接。接口采集的优点是可以实现异构系统之间的无缝集成，缺点是需要保证接口的稳定性和安全性。
- (4) **流式采集：** 通过处理实时数据流，捕捉数据的变化并及时上报。常用的流式采集工具有 Apache Kafka 和 StreamX 等。这些工具可以在分布式环境下处理高速数据流，并支持实时数据处理和分析。流式采集适用于处理实时数

据流，如金融交易、网络监控等场景。流式采集的优点是可以实时处理高速数据流，缺点是需要解决数据一致性和容错性等问题。目前，Kafka + Flink 已成为流式数据采集与处理的主流组合方案。云原生流式引擎（如 Ursa）的出现进一步降低了流式采集的基础设施成本。

- (5) **数据流自动化编排：** Apache NiFi 是一款强大的数据流自动化工具，支持数据路由、转换和系统中介逻辑的自动化编排。NiFi 提供了基于 Web 的可视化界面，用户可以通过拖拽方式构建从数据采集到预处理的数据流管道（ETL 流程），支持丰富的处理器（Processor）组件库，涵盖从各类数据源（数据库、消息队列、文件系统、云存储等）的读取、格式转换到目标写入的全流程。NiFi 的核心优势在于其数据 provenance（数据溯源）能力和背压（backpressure）机制，能够确保数据在传输过程中的可靠性和可追溯性。NiFi 适用于构建复杂的企业级数据集成管道，尤其在多源异构数据汇聚场景中表现出色。

四、数据处理

数据处理包括数据预处理（清洗、集成、转换）→ 分析建模 → 结果输出。其中，数据预处理是大数据分析的一个关键步骤，涉及清洗噪声数据（如缺失值、异常值）、集成多源数据、转换格式、规范化数据，以确保数据的质量、一致性和适用性。常见的数据处理工具如下：

- (1) Apache Spark： 是一个强大的分布式数据处理框架，支持批处理和实时数据处理。它提供了丰富的 API 来处理数据清洗、转换和集成等任务。Spark SQL 和 DataFrame API 使得数据处理更加便捷。当前，Spark 依然是离线批处理的绝对主流，Spark 4.0（2025 年发布）包含多项重大更新：Python API 大幅增强（PySpark 与原生 Spark 性能差距大幅缩小）、Spark Connect 稳定化（采用客户端-服务器分离架构，使 IDE 集成更流畅）、VARIANT 数

据类型（原生支持 JSON 和半结构化数据，JSON 处理性能提升可达 8 倍）以及对 Delta Lake 的深度原生支持。Spark 4.1（2026 年 1 月发布）进一步引入了实时模式（Real-Time Mode, RTM），使 Structured Streaming 能够实现毫秒级延迟，在高吞吐 ETL 和超低延迟流处理两个维度上均可胜任。

- (2) Tableau：是一个数据可视化工具，虽然主要用于数据分析和可视化，但它也提供了数据预处理的功能。通过 Tableau Prep，用户可以轻松地进行数据清洗、转换和准备。
- (3) TensorFlow：是一个开源机器学习库，主要用于深度学习模型的训练和预测。虽然它主要用于模型训练，但也可以用于数据预处理，特别是特征工程方面。
- (4) Apache Hive：是一个建立在 Hadoop 上的数据仓库基础设施，提供了一种类似 SQL 的查询语言 HiveQL，方便进行数据的 ETL（提取、转换、加载）操作。
- (5) Pentaho Business Analytics：是一个企业级的数据集成工具，支持大数据处理，能够连接到多种数据源，包括 NoSQL 数据库，并提供数据清洗和转换的功能。

五、大数据存储

数据存储是将预处理后的数据持久化保存，支持高效访问与管理。存储主要技术方案如下：

- (1) **分布式文件系统：** Hadoop Distributed File System (HDFS) 可用于存储大量数据，并能够以并行方式读写这些数据。HDFS 本质上是一个分布式文件系统，它将数据拆分为不同块并存储在多个服务器上。当需要访问存储在 HDFS 上的数据时，可以通过并行计算的方式访问多个块以提高数据访问速度。
- (2) **NoSQL 数据库：** HBase 是一种分布式数据库平台，它可以用于处理非结构化或半结构化的数据类型，并可以处理高速大数据流。此类分布式数据库系统可以水平扩展性和提供高可用性存储。
- (3) **传统数据仓库：** Apache Hive 是一个非常流行的数据仓库工具，它建立在 Hadoop 生态系统之上，允许用户以类似 SQL 的查询语言 (HiveQL) 来查询和分析存储在 Hadoop 文件系统 (HDFS) 中的大规模数据集。Hive 主要用于处理结构化数据，并且它提供了一个类似于传统数据库的架构。
- (4) **湖仓一体表格式 (Table Format)：** 这是当前大数据平台建设的主流选型方向。三大开源湖表格式通过在对象存储（如 HDFS 或 S3）之上添加事务层、变更数据捕获和时间旅行查询能力，打通了数据湖与数据仓库的边界。

六、数据分析

数据分析方法包括数据挖掘、机器学习、自然语言处理、统计分析和时间序列分析等，可以结合不同的数据类型、数据量、数据结构、分析目的和场景，选择不同的分析方法和工具。数据分析工具主要包括 Python 数据分析、R 语言数据分析等。

- (1) **Python：** 数据处理需要完成数据获取、数据清洗、数据探索、数据呈现、数据规模化和自动化的过程。主要包括：Python 基础知识，如何从 CSV、

Excel、XML、JSON 和 PDF 文件中提取数据，如何获取与存储数据，各种数据清洗与分析技术，数据可视化方法，如何从网站和 API 中提取数据等技能。R 语言也提供数据分析功能。

- (2) **R 语言：**适用于统计分析。在处理数据的过程中，经常根据需求从完整的实验设计和数据中筛选、整理出可以直接使用的部分，这就涉及到数据整理和变换工作。常用的数据整理和变换主要包括以下几类：选取特定分析变量、筛选满足条件的数据、按照某个变量排序、对数据进行分组和汇总。
- (3) **Hive：**是基于 Hadoop 的一个数据仓库工具，可以将结构化的数据文件映射为数据库表，并通过类 SQL 查询分析数据。用户无需编写 MapReduce 代码，通过 SQL 语句自动生成 MapReduce 任务执行计算，适合离线数据仓库的批处理统计分析。
- (4) **Apache Flink：****实时流处理**已成为数据分析的重要补充，Flink 是真正的逐事件（Event-by-Event）流处理，延迟可控制在毫秒级。**Flink 2.0**（2025 年发布）实现了核心架构的重大升级：存算分离架构（实现分离式状态管理，支持更大规模的状态管理、提升资源效率与容灾能力）、流批一体 API（开发者可以用同一套代码处理离线和实时两种场景）以及与 AI 场景的深度融合，推动实时计算向智能化演进。
- (5) **Feature Store：****特征平台**是 2026 年大数据工程与 AI 工程交汇最热的技术点。特征平台解决的是机器学习特征的复用性、一致性和线上线下一致（Training-Serving Skew）问题。Feast（开源）、Tecton（商业）及各大云厂商自研的特征平台（如阿里云 PAI FeatureStore）在企业大规模 AI 应用中的采用率快速上升。

七、数据可视化

数据可视化工具包括 Matplotlib、ECharts、NodeBox、Inkscape 等。

- (1) **Matplotlib** 是针对 Python 语言的一个开源、快速、易用的数据可视化库，能够生成线性图、条形图、散点图等多种类型的图形。
- (2) **ECharts** 是由百度开发的面向 Web 应用的一个开源可视化库，支持生成多种类型的图表，比如线性图、饼图、散点图等，支持响应式设计和动画效果。
- (3) **NodeBox** 是另一款基于 Python 语言的创意编程工具，它能够用 Python 代码生成复杂的 2D 和 3D 图形，支持交互式可视化和图形动画等效果。
- (4) **Inkscape** 是一款免费、开源的矢量图形编辑软件，用于绘制各种数据可视化图形和插图。
- (5) **Tableau** 是一个数据可视化工具，同时也具备强大的数据分析功能。
Tableau 通过直观的界面和拖放功能，使得用户可以轻松地创建各种类型的图表和仪表板，从而帮助用户更好地理解和分析数据。**Tableau 2025** 版本引入了多项 AI 驱动的新功能，包括 Tableau Agent（生成式 AI 助手，可用自然语言探索数据、创建可视化、生成计算公式）以及拖放式径向图制作、自定义调色板保存等功能。
- (6) **Power BI** 作为一款主流商业智能工具，在数据可视化领域与 Tableau 形成竞争格局，微软已在其产品中集成多种 AI 驱动的可视化效果。在开源可视化领域，**Plotly** 和 **Altair** 等 Python 交互式可视化库的使用率持续上升，可与 Jupyter Notebook 等数据分析环境无缝集成。

附录二：参考资料

1. (美) 韦斯·麦金尼 (Wes McKinney) . 利用Python进行数据分析 (第3版). 机械工业出版社, 2023年.
2. 张春福, 白婧, 张良均等. Python数据分析与挖掘实战 (第3版) . 机械工业出版社, 2025年.
3. (美) 朱尔斯·S·达米吉 (Jules S. Damji) , (美) 布鲁克·韦尼格 (Brooke Wenig) 等. Spark快速大数据分析 (第2版) . 人民邮电出版社, 2025年.
4. 刘月峰. Flink实时大数据处理技术. 机械工业出版社, 2024年.
5. 樊银亭, 夏敏捷, 宋宝卫. 数据可视化 (高等学校大数据专业系列教材) . 清华大学出版社, 2025年.
6. 刘伟等. 大数据分析与挖掘. 清华大学出版社, 2024年.
7. 吕云翔, 张扬等. Python网络爬虫技术与实践. 机械工业出版社, 2023年.
8. 余本国, 刘宁, 李春报. Python大数据分析与应用实战. 电子工业出版社, 2021年.
9. 邹庆士. 大数据分析与应用实战(统计机器学习之数据导向编程). 清华大学出版社, 2021年.
10. 吴明晖, 周苏. 大数据分析. 清华大学出版社, 2020年.
11. 周志华. 机器学习. 清华大学出版社, 2016年.
12. 徐华. 数据挖掘: 方法与应用 (第2版) . 清华大学出版社, 2022年.